

# Análise Exploratória de Dados Municipais de Minas Gerais

Introdução à Ciência de Dados

Ana Luiza, Carolina, Samara, Tainá

2026-06-22

## Índice

|          |                                           |           |
|----------|-------------------------------------------|-----------|
| <b>1</b> | <b>Introdução</b>                         | <b>2</b>  |
| <b>2</b> | <b>Objetivos</b>                          | <b>2</b>  |
| <b>3</b> | <b>Metodologia</b>                        | <b>2</b>  |
| <b>4</b> | <b>Visualização e Tratamento de dados</b> | <b>3</b>  |
| 4.1      | Banco de Dados . . . . .                  | 3         |
| 4.2      | Carregando Pacotes . . . . .              | 3         |
| 4.3      | Visualização de Dados . . . . .           | 4         |
| 4.4      | Tratamento de Dados . . . . .             | 4         |
| <b>5</b> | <b>Análise Descritiva</b>                 | <b>6</b>  |
| 5.1      | Histogramas . . . . .                     | 7         |
| 5.2      | Boxplots . . . . .                        | 14        |
| <b>6</b> | <b>Rankings</b>                           | <b>20</b> |
| <b>7</b> | <b>Associações e Correlações</b>          | <b>23</b> |
| 7.1      | Gráficos . . . . .                        | 23        |
| 7.1.1    | Gráfico - Receita Bruta x IDHM . . . . .  | 23        |
| 7.1.2    | Gráfico - Escolarização x IDHM . . . . .  | 26        |
| 7.1.3    | Gráfico - IDHM x Mortalidade . . . . .    | 29        |
| 7.1.4    | Gráfico - PIB x IDHM . . . . .            | 32        |
| 7.1.5    | Gráfico - Receita x Despesa . . . . .     | 35        |

|           |                                      |           |
|-----------|--------------------------------------|-----------|
| 7.2       | Resumo Correlações . . . . .         | 36        |
| 7.2.1     | Associação entre Variáveis . . . . . | 36        |
| 7.2.2     | Tabela Resumo . . . . .              | 37        |
| 7.2.3     | Matriz de Correlação Geral . . . . . | 38        |
| <b>8</b>  | <b>Conclusão</b>                     | <b>39</b> |
| <b>9</b>  | <b>Referências</b>                   | <b>40</b> |
| <b>10</b> | <b>Apêndice</b>                      | <b>40</b> |

## 1 Introdução

Minas Gerais é o segundo estado mais populoso do Brasil e possui 853 municípios, sendo o estado com o maior número de municípios do país. Essa grande diversidade entre as cidades permite analisar diferentes realidades socioeconômicas presentes no território mineiro. Enquanto municípios como Belo Horizonte e Uberlândia apresentam maior concentração populacional e econômica, muitas cidades de menor porte, principalmente nas regiões norte e noroeste do estado, enfrentam desafios relacionados ao desenvolvimento humano e à infraestrutura.

Este relatório apresenta uma Análise Exploratória de Dados utilizando indicadores municipais de Minas Gerais disponibilizados pelo IBGE. Foram analisadas variáveis relacionadas à população, território, educação, saúde, economia e desenvolvimento humano.

## 2 Objetivos

Realizar uma análise exploratória de dados dos municípios do estado de Minas Gerais, utilizando técnicas de estatística descritiva e visualização de dados, com o propósito de identificar padrões, relações e tendências entre indicadores socioeconômicos, financeiros e demográficos, gerando insights que auxiliem na compreensão das características municipais.

## 3 Metodologia

A metodologia adotada neste trabalho foi estruturada em etapas de aquisição, tratamento, análise e interpretação dos dados, seguindo os princípios da análise exploratória de dados.

Inicialmente, foi utilizada uma base de dados contendo informações socioeconômicas, financeiras e demográficas dos municípios de Minas Gerais, disponibilizada em formato tabular. Os dados foram importados para o ambiente de análise utilizando a linguagem R, por meio de bibliotecas especializadas em manipulação, visualização e análise estatística.

Na etapa de pré-processamento, realizou-se a limpeza dos dados, incluindo verificação de valores ausentes, padronização de variáveis, tratamento de inconsistências e adequação dos tipos de dados. Posteriormente, foi conduzida uma análise descritiva com o cálculo de medidas resumo, como média, mediana, quartis, valores mínimos e máximos.

Em seguida, foram aplicadas técnicas de visualização de dados para explorar a distribuição das variáveis e investigar possíveis relações entre os indicadores analisados. Para isso, foram utilizados histogramas, boxplots, gráficos de dispersão, matrizes de correlação e outras representações gráficas relevantes.

Por fim, os resultados foram interpretados com foco na identificação de tendências e associações entre os indicadores municipais, permitindo uma compreensão mais aprofundada das características socioeconômicas dos municípios analisados.

## **4 Visualização e Tratamento de dados**

### **4.1 Banco de Dados**

A base de dados utilizada neste projeto contém informações oficiais sobre os 853 municípios do estado de Minas Gerais, coletadas a partir de dados do Instituto Brasileiro de Geografia e Estatística (IBGE).

O arquivo reúne indicadores socioeconômicos e demográficos importantes para a análise, organizados nas seguintes categorias:

Identificação Local: Códigos de identificação do IBGE, nomes das cidades e as respectivas mesorregiões e microrregiões do estado.

População e Economia: Dados sobre o total de habitantes, a densidade demográfica (habitantes por quilômetro quadrado) e o Produto Interno Bruto (PIB) de cada município.

Desenvolvimento Social: Indicadores de IDH (Índice de Desenvolvimento Humano), taxas de alfabetização e os valores do IDH divididos por educação, longevidade e renda.

Essa estrutura permite cruzar os dados regionais para identificar quais áreas de Minas Gerais apresentam melhores indicadores e quais regiões necessitam de maior atenção em políticas públicas.

### **4.2 Carregando Pacotes**

```
library(tidyverse)
library(readxl)
library(janitor)
library(dplyr)
library(scales)
library(ggplot2)
library(kableExtra)
library(corrplot)
library(htmltools)
library(plotly)
library(webshot2)
```

### 4.3 Visualização de Dados

```
Rows: 853
Columns: 11
$ `Município [-]` <chr> ~
$ `Área Territorial - km² [2025]` <dbl> ~
$ `População no último censo - pessoas [2022]` <dbl> ~
$ `Densidade demográfica - hab/km² [2022]` <dbl> ~
$ `População estimada - pessoas [2025]` <dbl> ~
$ `Escolarização <span>6 a 14 anos</span> - % [2022]` <dbl> ~
$ `IDHM <span>Índice de desenvolvimento humano municipal</span> [2010]` <dbl> ~
$ `Mortalidade infantil - óbitos por mil nascidos vivos [2023]` <chr> ~
$ `Total de receitas brutas realizadas - R$ [2024]` <dbl> ~
$ `Total de despesas brutas empenhadas - R$ [2024]` <dbl> ~
$ `PIB per capita - R$ [2023]` <dbl> ~
```

### 4.4 Tratamento de Dados

Na etapa de tratamento dos dados, o código realiza a limpeza, a padronização e a validação das informações da base original. Primeiro, os nomes das colunas são padronizados para o formato snake\_case e renomeados para termos mais curtos e claros, facilitando a manipulação e eliminando termos técnicos longos do IBGE. Em seguida, na variável de mortalidade infantil, os caracteres que indicavam valores ausentes são substituídos por um formato numérico reconhecido pelo sistema. Por fim, o código calcula de forma independente a densidade demográfica, dividindo a população do último censo pela área territorial, e usa esse valor calculado para corrigir a coluna original caso seja detectada qualquer diferença significativa, garantindo a consistência interna e a precisão dos dados estatísticos analisados.

```

df_limpo <- df %>%

clean_names() %>%
  rename(
    municipio = municipio,
    areaTerritorial_km2 = area_territorial_km2_2025,
    populacao_ultimoCenso = populacao_no_ultimo_censo_pessoas_2022,
    densidadeDemografica = densidade_demografica_hab_km2_2022,
    populacaoEstimada = populacao_estimada_pessoas_2025,
    escolarizacao_6a14 = escolarizacao_span_6_a_14_anos_span_percent_2022,
    idhm = idhm_span_indice_de_desenvolvimento_humano_municipal_span_2010,
    mortalidadeInfantil_obitosPor1000 = mortalidade_infantil_obitos_por_mil_nascidos_vivos_2022,
    total_ReceitasBrutas = total_de_receitas_brutas_realizadas_r_2024,
    total_DespesasBrutas = total_de_despesas_brutas_empenhadas_r_2024,
    pib_percapita = pib_per_capita_r_2023
  ) %>%

  mutate(
    mortalidadeInfantil_obitosPor1000 =
      mortalidadeInfantil_obitosPor1000 %>%
      na_if("-") %>%
      as.numeric()
  ) %>%

  mutate(
    densidade_calculada =
      populacao_ultimoCenso /
      areaTerritorial_km2,

    densidadeDemografica =
      if_else(
        abs(
          densidadeDemografica -
          densidade_calculada
        ) > 0.01,
        round(densidade_calculada, 2),
        densidadeDemografica
      )
  ) %>%

  select(-densidade_calculada)

```


## 5 Análise Descritiva

Tabela 1: Medidas resumo com CV e assimetria


| Variável                | N   | Mínimo   | Q1        | Mediana   | Média     | Q3        | Máximo       | De |
|-------------------------|-----|----------|-----------|-----------|-----------|-----------|--------------|----|
| Área (km <sup>2</sup> ) | 853 | 3,56     | 196,74    | 363,82    | 687,59    | 727,89    | 10.727,10    |    |
| Pop. Censo 2022         | 853 | 833,00   | 4.639,00  | 8.048,00  | 24.079,71 | 17.285,00 | 2.315.560,00 |    |
| Dens. Demográfica       | 853 | 1,21     | 12,17     | 22,09     | 69,11     | 43,76     | 6.988,53     |    |
| Escolarização (%)       | 853 | 84,92    | 98,66     | 99,29     | 98,99     | 100,00    | 100,00       |    |
| IDHM                    | 853 | 0,53     | 0,63      | 0,67      | 0,67      | 0,70      | 0,81         |    |
| Mortalidade Infantil    | 559 | 1,95     | 9,93      | 14,51     | 18,66     | 23,12     | 100,00       |    |
| PIB per capita (R\$)    | 853 | 9.139,92 | 18.176,41 | 24.727,70 | 34.487,09 | 37.293,07 | 377.790,63   |    |

A tabela apresenta o resumo estatístico das principais variáveis quantitativas dos municípios de Minas Gerais, exibindo para cada indicador o número total de observações, os valores mínimo e máximo, a média, o desvio padrão e o coeficiente de assimetria. Esta última coluna, correspondente à assimetria, é fundamental para compreender o comportamento e a distribuição dos dados de cada variável, pois valores próximos de zero indicam uma distribuição mais simétrica em torno da média, enquanto valores positivos e elevados revelam uma distribuição com cauda alongada para a direita, o que significa que a maior parte dos municípios se concentra em valores mais baixos daquele indicador, enquanto apenas um grupo restrito de cidades apresenta valores muito altos, puxando a média geral para cima.


## 5.1 Histogramas



O histograma possui assimetria à esquerda. A maioria esmagadora dos municípios está concentrada na última faixa (entre 98% e 100%), indicando a quase universalização do ensino nessa idade.




Apresenta um formato de sino quase simétrico. A maior parte dos municípios se concentra no centro do gráfico (em torno do valor de 0,67), demonstrando um padrão de desenvolvimento médio consistente no estado.




A distribuição é assimétrica à direita. A concentração principal ocorre nas faixas mais bai-




xas, mas o gráfico possui uma cauda longa que revela a existência de municípios com taxas elevadas.



Mostra forte assimetria à direita. A maior barra está no limite inferior, demonstrando que a grande maioria dos municípios mineiros possui um PIB per capita baixo.




O gráfico apresenta uma distribuição fortemente assimétrica à direita, indicando que a grande maioria dos municípios tem área pequena, concentrando-se nas primeiras faixas do gráfico.




Distribuição com assimetria extrema à direita. Quase todos os 853 municípios de MG têm


pequeno porte populacional, gerando um pico único no primeiro intervalo.



A distribuição é extremamente assimétrica à direita. Quase todos os municípios se agrupam no primeiro intervalo (baixa densidade), refletindo o perfil de cidades pequenas do interior do estado.




Segue o exato mesmo padrão populacional do Censo 2022, com assimetria extrema à direita e concentração maciça nas cidades de pequeno porte.




Semelhante às despesas, o histograma é altamente concentrado à esquerda. A maior parte das

idades capta valores baixos, evidenciando o abismo orçamentário para as grandes metrópoles.




Distribuição de assimetria extrema à direita. O pico absoluto nos valores baixos reflete os orçamentos das inúmeras cidades pequenas, enquanto poucas cidades grandes distorcem o eixo x.


## 5.2 Boxplots



O boxplot é invertido em relação aos demais, com a mediana encostada no topo (99,2%). Apresenta vários outliers inferiores, representando cidades que não atingiram a universalização do ensino.




É o boxplot mais bem distribuído e com menor dispersão. A caixa é simétrica ao redor da mediana e existem pouquíssimos outliers (apenas 3 pontinhos fora da curva).




Apresenta uma mediana baixa (14,5), mas revela grande dispersão superior. Há muitos outliers

(pontos acima do limite), que são os municípios com indicadores de saúde mais críticos.




O boxplot possui a caixa compacta na parte inferior do gráfico, com a presença de mais de 80 outliers superiores que indicam cidades excepcionalmente ricas, puxando a média para cima.







A caixa é achatada próximo à base, com uma mediana baixa (363 km<sup>2</sup>), e apresenta muitos outliers superiores que representam os poucos municípios com territórios muito extensos.



A visualização do bloco central (50% dos dados) é quase invisível devido à distorção gerada por cerca de 100 outliers populacionais extremos, liderados por Belo Horizonte e outras capitais regionais.




Os dados estão quase totalmente colados no eixo inferior. A presença de outliers com densidade altíssima (como a capital) comprime toda a caixa para perto de zero.




A dispersão e os outliers acompanham o Censo 2022. A mediana populacional baixíssima e a

enorme quantidade de outliers superiores espremem a representação visual da caixa.



O padrão de dispersão é idêntico ao das despesas. Os pontos discrepantes na parte superior representam a alta arrecadação das grandes metrópoles, o que comprime a mediana da maioria dos municípios no piso do gráfico.



O boxplot é severamente comprimido para baixo. Os outliers superiores possuem cifras tão colossais que os dados orçamentários das cidades comuns viram uma linha no fundo do eixo Y.


## 6 Rankings

Tabela 2: 10 municípios com maior área territorial (MG, 2025)

| Município     | Área (km <sup>2</sup> ) | Pop. 2022 | Dens. (hab/km <sup>2</sup> ) | IDHM  | PIB pc (R\$) |
|---------------|-------------------------|-----------|------------------------------|-------|--------------|
| João Pinheiro | 10.727                  | 46.801    | 4.36                         | 0.697 | R\$ 54.758   |
| Unaí          | 8.445                   | 86.619    | 10.26                        | 0.736 | R\$ 60.282   |
| Paracatu      | 8.231                   | 94.023    | 11.42                        | 0.744 | R\$ 72.311   |
| Buritizeiro   | 7.218                   | 23.910    | 3.31                         | 0.624 | R\$ 35.636   |
| Januária      | 6.662                   | 65.150    | 9.78                         | 0.658 | R\$ 15.971   |
| Arinos        | 5.279                   | 17.272    | 3.27                         | 0.656 | R\$ 31.529   |
| Buritis       | 5.225                   | 24.030    | 4.60                         | 0.672 | R\$ 60.181   |
| Prata         | 4.848                   | 28.342    | 5.85                         | 0.695 | R\$ 60.076   |
| Uberaba       | 4.524                   | 337.836   | 74.68                        | 0.772 | R\$ 70.121   |
| Uberlândia    | 4.115                   | 713.224   | 173.31                       | 0.789 | R\$ 71.598   |

## 10 Maiores Municípios por Área Territorial

Cor indica PIB per capita — municípios maiores em extensão territo





## 7 Associações e Correlações

### 7.1 Gráficos

#### 7.1.1 Gráfico - Receita Bruta x IDHM



O cruzamento entre a receita do município e o IDHM mostra que o orçamento ajuda a cidade a se desenvolver, mas esse efeito tem um limite. No início do gráfico, qualquer aumento na arrecadação provoca um salto rápido no IDHM. Porém, conforme as cidades se tornam mais ricas, o índice tende a estabilizar. Isso sinaliza que, a partir de um certo nível financeiro, ter mais dinheiro não garante o avanço social de forma automática; o resultado passa a depender de investimentos bem direcionados em saúde e educação.

#### **7.1.1.1 Correlação - Receita Bruta x IDHM**

$n = 853$

Pearson  $r = 0.271$

Spearman  $r_s = 0.463$


p-valor = 0

O coeficiente de Pearson obtido ( $r = 0,271$ ) classifica a associação como fraca, enquanto o Spearman ( $r = 0,463$ ) eleva-a ao nível moderado. A divergência entre os dois coeficientes evidencia o efeito de valores extremos: municípios de grande porte, como Belo Horizonte e Uberlândia, apresentam receitas muito elevadas em razão da sua população, mas seus IDHMs, embora altos, não são proporcionalmente superiores aos de municípios menores e bem desenvolvidos. O Spearman, ao operar com os postos das observações, não é sensível a essas distâncias absolutas e captura com maior fidelidade a tendência geral de que municípios com maior capacidade fiscal tendem a alcançar melhores indicadores de desenvolvimento humano — relação esperada, uma vez que mais recursos permitem maior investimento em saúde, educação e infraestrutura.





7.1.2 Gráfico - Escolarização x IDHM



Este gráfico apresenta uma das relações mais claras do estudo. Fica evidente que as cidades que conseguem manter as crianças de 6 a 14 anos na escola são, sem exceção, aquelas que alcançam os maiores níveis de IDHM. O dado confirma que o acesso à educação básica é um fator essencial para o desenvolvimento geral do município.

#### 7.1.2.1 Correlação - Escolarização x IDHM

n = 853

Pearson  $r = -0.014$


Spearman  $r_s = -0.089$

p-valor = 0.6883

O resultado obtido para este par é o mais intrigante da análise: o coeficiente de Pearson é praticamente nulo ( $r = -0,014$ ) e o Spearman confirma ausência de associação ( $r = -0,089$ ). À primeira vista, parece contraditório que escolarização e desenvolvimento humano não se correlacionem. No entanto, os dados revelam um fenômeno de “efeito de teto”: a taxa de escolarização de 6 a 14 anos já ultrapassa 98% em praticamente todos os municípios mineiros, com mediana de 99,3%, o que significa que o acesso à escola nessa faixa etária foi amplamente universalizado no estado. Quando uma variável apresenta variação muito pequena, ela perde capacidade discriminatória e, conseqüentemente, não consegue estabelecer correlação com nenhuma outra variável — independentemente da relação conceitual entre elas. O valor faz sentido no contexto atual de MG, ainda que não reflita a relação estrutural mais ampla entre educação e desenvolvimento.



### 7.1.3 Gráfico - IDHM x Mortalidade



O gráfico que combina o IDHM com a mortalidade infantil confirma a tendência esperada: quanto melhor o desenvolvimento humano da cidade, menor é a taxa de mortalidade de crianças. No entanto, existem exceções importantes que quebram essa regra. O município de Ribeirão Vermelho é um exemplo disso: apesar de ter um IDHM considerado alto (0,700), a cidade registra uma taxa de mortalidade infantil elevada, o que aponta para falhas específicas nos serviços de saúde local.

#### 7.1.3.1 Correlação - IDHM x Mortalidade

`n = 559`

`Pearson r = -0.238`

`Spearman rs = -0.314`

`p-valor = 0`

A correlação negativa fraca ( $r = -0,238$ ;  $r = -0,314$ ) confirma a direção esperada: municípios com IDHM mais elevado tendem a registrar menor mortalidade infantil, reflexo de um acesso mais amplo a saneamento básico, serviços de saúde e condições socioeconômicas mais favoráveis. A intensidade contida do coeficiente, porém, merece atenção. Dois fatores explicam a fraqueza da associação: a defasagem temporal de 13 anos entre as fontes (IDHM de 2010 e mortalidade de 2023), que dilui a relação por mudanças ocorridas no período; e a ausência de dados de mortalidade em 294 municípios — cerca de 34% do total —, pois o IBGE omite esse indicador em localidades com poucos nascimentos, onde a taxa seria estatisticamente instável. A análise se baseia, portanto, em 559 municípios. O p-valor confirma que a correlação é estatisticamente significativa a 5%, e o valor encontrado faz sentido no contexto do problema.



7.1.4 Gráfico - PIB x IDHM





A análise do gráfico mostra que o crescimento econômico ajuda o desenvolvimento humano até certo ponto. No início da curva, nota-se uma relação muito clara: pequenos aumentos no PIB resultam em grandes melhoras no IDHM. No entanto, quando olhamos para as cidades de maior renda, a curva começa a estabilizar. Esse comportamento deixa evidente que, depois que o município garante uma base financeira mínima, o avanço social não acontece mais de forma automática com o crescimento da economia. A partir desse nível, melhorar o IDHM passa a depender diretamente de investimentos focados em saúde e educação.

#### 7.1.4.1 Correlação - PIB x IDHM

$n = 853$

Pearson  $r = 0.39$


Spearman  $r_s = 0.702$

p-valor = 0

Este par representa o caso mais revelador da análise, ao demonstrar a importância de se comparar os coeficientes de Pearson e Spearman. O Pearson ( $r = 0,390$ ) aponta associação fraca/moderada, ao passo que o Spearman ( $r = 0,702$ ) indica relação\*forte. A discrepância decorre da assimetria extrema do PIB per capita em MG: municípios como Extrema, Catas Altas e Itatiaiuçu registram valores acima de R\$ 300 mil, impulsionados por grandes plantas industriais ou mineradoras instaladas em populações reduzidas. Esses valores extremos distorcem a correlação linear de Pearson, que é sensível a outliers, conforme destacado no material teórico. O Spearman, ao trabalhar apenas com os postos das observações, é imune a essas distâncias absolutas e revela que, em termos de ordenação, municípios mais ricos tendem consistentemente a apresentar IDHM mais alto — uma relação forte e positiva, coerente com o esperado no contexto socioeconômico de Minas Gerais.



7.1.5 Gráfico - Receita x Despesa



O gráfico mostra uma linha reta bem definida, onde os dados acompanham quase perfeitamente a linha diagonal. O tamanho das bolhas reflete a grande diferença econômica entre as cidades, mostrando que os grandes municípios movimentam bilhões, enquanto os pequenos têm recursos muito baixos. O ponto mais importante do gráfico é a falta de sobra no orçamento: a quase totalidade das cidades de Minas Gerais opera no limite entre o que arrecada e o que gasta. Essa proximidade com o limite financeiro mostra que as prefeituras não têm margem de manobra ou reserva em caixa, o que deixa a gestão pública muito dependente e vulnerável a qualquer queda na arrecadação.

#### 7.1.5.1 Correlação - Receitas x Despesas

$n = 853$

Pearson  $r = 0.995$

Spearman  $r_s = 0.982$

p-valor = 0

A correlação entre receitas e despesas municipais é muito forte, quase perfeita ( $r = 0,995$ ;  $r_s = 0,982$ ), com plena concordância entre os três coeficientes. Esse resultado é o mais esperado de toda a análise: a Lei de Responsabilidade Fiscal (Lei Complementar nº 101/2000) impõe equilíbrio orçamentário aos municípios brasileiros, estabelecendo limites ao endividamento e vedando gastos sistematicamente superiores à arrecadação. Por força legal, portanto, receita e despesa caminham juntas — municípios que arrecadam mais naturalmente comprometem maior volume de recursos, e na mesma proporção. A quase perfeição da correlação confirma que esse princípio é seguido de forma consistente pela totalidade dos municípios mineiros analisados.

## 7.2 Resumo Correlações

### 7.2.1 Associação entre Variáveis

Para quantificar as relações identificadas nos gráficos anteriores, foram calculados os coeficientes de correlação de Pearson ( $r$ ), Spearman ( $r_s$ ) e Kendall ( $\tau$ ) para cada par de variáveis. O coeficiente de Pearson mede a intensidade da associação linear entre duas variáveis, enquanto Spearman e Kendall trabalham com os postos das observações, sendo mais robustos à presença de valores extremos e à assimetria das distribuições. A força da correlação é classificada segundo o critério adotado na disciplina: correlação **fraca** quando  $|r| < 0,4$ ; **moderada** quando  $0,4 \leq |r| < 0,7$ ; **forte** quando  $0,7 \leq |r| < 1$ ; e **perfeita** quando  $|r| = 1$ .

## 7.2.2 Tabela Resumo

Tabela 3: Resumo dos coeficientes de correlação — municípios de MG

| Par de Variáveis            | n   | Pearson (r) | Spearman (r ) | Força                 | Sentido  |
|-----------------------------|-----|-------------|---------------|-----------------------|----------|
| IDHM × Mortalidade Infantil | 559 | -0.238      | -0.314        | Fraca                 | Negativo |
| Escolarização × IDHM        | 853 | -0.014      | -0.089        | Nula                  | Negativo |
| Receitas × IDHM             | 853 | 0.271       | 0.463         | Fraca/Modera-<br>da*  | Positivo |
| PIB per capita × IDHM       | 853 | 0.390       | 0.702         | Modera-<br>da/Forte** | Positivo |
| Receitas × Despesas         | 853 | 0.995       | 0.982         | Muito Forte           | Positivo |

A tabela consolida os coeficientes calculados para os cinco pares, permitindo uma comparação direta entre a força e o sentido de cada associação.

Pearson fraco ( $r = 0,271$ ) e Spearman moderado ( $r = 0,463$ ): municípios populosos distorcem o coeficiente linear.\*

Pearson moderado ( $r = 0,390$ ) e Spearman forte ( $r = 0,702$ ): outliers extremos de PIB per capita distorcem o Pearson; o Spearman é o indicador mais adequado para este par.

IDHM × Mortalidade Infantil: A correlação negativa fraca faz sentido: municípios mais desenvolvidos tendem a ter menor mortalidade infantil, por conta de melhor acesso à saúde e saneamento. A fraqueza do coeficiente é explicada pela defasagem de 13 anos entre as fontes (IDHM de 2010, mortalidade de 2023) e pela ausência de dados em municípios pequenos.

Escolarização × IDHM: A correlação nula faz sentido no contexto atual de MG: a escolarização básica já é praticamente universal no estado (mediana de 99,3%), portanto essa variável não discrimina mais os municípios entre si. Não significa que educação e desenvolvimento sejam independentes — significa que esse indicador específico já atingiu seu teto.


Receitas × IDHM: A correlação positiva moderada (pelo Spearman) faz sentido: municípios com maior capacidade fiscal tendem a investir mais em serviços públicos, o que se reflete no IDHM. A relação não é perfeita pois a eficiência do gasto varia muito entre municípios.

PIB per capita × IDHM: A correlação forte (pelo Spearman) faz sentido e é o par mais interessante analiticamente: o Pearson subestima a relação por causa de outliers extremos (municípios com grandes mineradoras ou indústrias), mas o Spearman revela que, em termos de ordem, riqueza e desenvolvimento humano caminham juntos de forma consistente em MG.

Receitas × Despesas: A correlação quase perfeita faz sentido e é totalmente esperada: a Lei de Responsabilidade Fiscal obriga os municípios a manterem equilíbrio orçamentário, fazendo com que receita e despesa sejam, por estrutura legal, praticamente proporcionais.

Com base nos dados da tabela de resumo, é possível concluir que os valores, no geral, fazem sentido. Os coeficientes encontrados são coerentes com o que se conhece sobre os municípios de Minas Gerais.

### 7.2.3 Matriz de Correlação Geral



A matriz de correlação de Pearson entre todas as variáveis numéricas da base amplia a perspectiva da análise e permite identificar associações que não foram exploradas individualmente.

A quase colinearidade entre receitas e despesas ( $r \approx 1,00$ ) é confirmada visualmente como a relação mais intensa de toda a base. O IDHM apresenta correlação moderada apenas com o PIB per capita, e fraca com as demais variáveis, indicando que o desenvolvimento humano municipal em MG é um fenômeno multidimensional que nenhuma variável econômica isolada consegue explicar com plenitude. A baixa correlação linear do PIB per capita com as demais variáveis reforça o impacto dos outliers extremos já discutido, que comprometem o coeficiente de Pearson nessa variável.

## 8 Conclusão

A Análise Exploratória de Dados dos 853 municípios de Minas Gerais apresenta um cenário territorial com fortes assimetrias demográficas e econômicas. A avaliação conjunta dos indicadores levanta algumas hipóteses importantes sobre a dinâmica de desenvolvimento do estado:

### Concentração de População e Recursos:

A análise descritiva mostra uma forte assimetria na maioria das variáveis (como População, PIB per capita, Receitas e Despesas). Isso sugere que a base do estado é formada por muitos municípios pequenos e com arrecadação limitada. Por outro lado, observa-se que poucos polos econômicos concentram grande parte da riqueza, o que parece puxar as médias estaduais para cima e criar distorções na distribuição geral.

### Hipótese do Teto de Crescimento Econômico no Social:

O cruzamento das variáveis financeiras (como o PIB per capita) com o IDHM indica uma correlação positiva, porém não linear. A hipótese levantada pelos gráficos é que o aumento financeiro impulsiona o desenvolvimento humano de forma rápida nos estágios iniciais. No entanto, nas cidades mais ricas, essa curva tende a se estabilizar. Esse comportamento sugere que o alto volume de recursos, isoladamente, pode não garantir melhorias contínuas na qualidade de vida, apontando para a possível necessidade de uma gestão mais focada em políticas sociais a partir de certo patamar financeiro.

### Indícios de Orçamentos Restritos:

A correlação quase perfeita entre Receitas e Despesas Brutas pode ser interpretada como um reflexo do cumprimento da Lei de Responsabilidade Fiscal. Contudo, na prática, essa linearidade forte levanta a hipótese de que a esmagadora maioria das prefeituras opera no limite de seus orçamentos. O uso de quase toda a arrecadação para cobrir gastos e obrigações legais pode indicar que as administrações locais possuem pouca margem financeira para realizar novos investimentos de forma autônoma.

### Escolarização e Dinâmicas de Saúde:

Os dados mostram que a taxa de escolarização de 6 a 14 anos está praticamente universalizada na maior parte do estado (mediana de 99,3%), criando um “efeito de teto” nos modelos estatísticos. Na área da saúde, a relação entre IDHM e Mortalidade Infantil acompanha a tendência de que um maior desenvolvimento reduz a mortalidade. Porém, a presença de municípios com IDHM razoável e mortalidade elevada levanta a hipótese de que existem desafios locais específicos na gestão da saúde, enquanto regiões com números muito baixos podem estar sofrendo com possíveis subnotificações nos registros do governo.

Em síntese, a exploração inicial dos dados sugere que os desafios de Minas Gerais vão além da geração de riqueza, passando possivelmente pela forma como os recursos são distribuídos e convertidos em bem-estar. A superação das desigualdades parece demandar políticas que considerem a realidade dos municípios menores, que operam com orçamentos ajustados e podem necessitar de apoio para sustentar o avanço do seu desenvolvimento humano a longo prazo.

## 9 Referências

WICKHAM, H. et al. Welcome to the tidyverse. Journal of Open Source Software, 2019. WICKHAM, H. ggplot2: Elegant Graphics for Data Analysis. Springer, 2016. SIEVERT, C. Interactive Web-Based Data Visualization with R, plotly, and shiny. CRC Press, 2020. POSIT SOFTWARE, PBC. Quarto Documentation. Disponível em: Quarto Documentation. Acesso em: 22 jun. 2026.

R Core Team (2026). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria. doi:10.32614/R.manuals <https://doi.org/10.32614/R.manuals>. <https://www.R-project.org/>.

## 10 Apêndice

```
library(bslib)
library(bsicons)
library(readxl)
library(tidyverse)
library(readxl)
library(janitor)
library(dplyr)
library(scales)
library(ggplot2)
library(kableExtra)
library(corrplot)
```



```

library(htmltools)
library(plotly)

df <- read_excel("dados/BaseDadosIBGE_MG.xlsx")

cidadesTotais <- df %>%
  summarise(`Município [-]` = n(), .groups = "drop")

value_box(
  title = "Número de Municípios",
  value = cidadesTotais,
  showcase = bsicons::bs_icon("geo-alt"),
  theme = value_box_theme(bg = "#e6f2fd", fg = "#0B538E"),
  class = "border"
)

mediaIDHM <- df %>%
  summarise(media = mean(`IDHM <span>Índice de desenvolvimento humano municipal</span> [2010]`
    na.rm = TRUE))

value_box(
  title = "Média do IDHM",
  value = round(mediaIDHM, 3),
  showcase = bsicons::bs_icon("people"),
  theme = value_box_theme(bg = "#e6f2fd", fg = "#0B538E"),
  class = "border"
)

mediaMortalidade <- df %>%
  mutate(
    `Mortalidade infantil - óbitos por mil nascidos vivos [2023]` =
      `Mortalidade infantil - óbitos por mil nascidos vivos [2023]` %>%
        na_if("-") %>%
        as.numeric()
  ) %>%
  summarise(media = mean(`Mortalidade infantil - óbitos por mil nascidos vivos [2023]`,
    na.rm = TRUE))

value_box(
  title = "Média da Mortalidade Infantil",
  value = round(mediaMortalidade, 2),
  showcase = bsicons::bs_icon("heart-pulse"),

```

```

    theme = value_box_theme(bg = "#e6f2fd", fg = "#0B538E"),
    class = "border"
  )

mediaPIB <- df %>%
  summarise(media = mean(`PIB per capita - R$ [2023]`, na.rm = TRUE))

value_box(
  title = "Média do PIB",
  value = round(mediaPIB, 2),
  showcase = bsicons::bs_icon("cash-coin"),
  theme = value_box_theme(bg = "#e6f2fd", fg = "#0B538E"),
  class = "border"
)

glimpse(df)

df_limpo <- df %>%

clean_names() %>%
  rename(
    municipio = municipio,
    areaTerritorial_km2 = area_territorial_km2_2025,
    populacao_ultimoCenso = populacao_no_ultimo_censo_pessoas_2022,
    densidadeDemografica = densidade_demografica_hab_km2_2022,
    populacaoEstimada = populacao_estimada_pessoas_2025,
    escolarizacao_6a14 = escolarizacao_span_6_a_14_anos_span_percent_2022,
    idhm = idhm_span_indice_de_desenvolvimento_humano_municipal_span_2010,
    mortalidadeInfantil_obitosPor1000 = mortalidade_infantil_obitos_por_mil_nascidos_vivos_2022,
    total_ReceitasBrutas = total_de_receitas_brutas_realizadas_r_2024,
    total_DespesasBrutas = total_de_despesas_brutas_empenhadas_r_2024,
    pib_percapita = pib_per_capita_r_2023
  ) %>%

# 2. Tratar mortalidade infantil
mutate(
  mortalidadeInfantil_obitosPor1000 =
    mortalidadeInfantil_obitosPor1000 %>%
    na_if("-") %>%
    as.numeric()
) %>%

```

```

# 3. Corrigir densidade demográfica
mutate(
  densidade_calculada =
    populacao_ultimoCenso /
    areaTerritorial_km2,

  densidadeDemografica =
    if_else(
      abs(
        densidadeDemografica -
        densidade_calculada
      ) > 0.01,
      round(densidade_calculada, 2),
      densidadeDemografica
    )
) %>%

select(-densidade_calculada)

resumo <- function(x, nome) {
  x <- na.omit(x)
  cv <- sd(x) / mean(x) * 100
  assimetria <- (mean(x) - median(x)) / sd(x)
  tibble(
    Variável = nome,
    N = length(x),
    Mínimo = min(x),
    Q1 = quantile(x, 0.25),
    Mediana = median(x),
    Média = mean(x),
    Q3 = quantile(x, 0.75),
    Máximo = max(x),
    `Desv. Padrão` = sd(x),
    `CV (%)` = cv,
    Assimetria = assimetria
  )
}

bind_rows(
  resumo(df_limpo$areaTerritorial_km2, "Área (km²)"),
  resumo(df_limpo$populacao_ultimoCenso, "Pop. Censo 2022"),
  resumo(df_limpo$densidadeDemografica, "Dens. Demográfica"),

```

```

resumo(df_limpo$escolarizacao_6a14, "Escolarização (%)",
resumo(df_limpo$idhm, "IDHM"),
resumo(df_limpo$mortalidadeInfantil_obitosPor1000, "Mortalidade Infantil"),
resumo(df_limpo$pib_percapita, "PIB per capita (R$)")
) |>
kable(digits = 2, caption = "Medidas resumo com CV e assimetria",
      booktabs = TRUE, format.args = list(big.mark = ".")) |>
kable_styling(latex_options = c("hold_position", "scale_down"), font_size = 8)

ggplot(df_limpo, aes(y = escolarizacao_6a14)) +
  geom_boxplot(
    fill = "#5A84B3",
    color = "#1F4E79",
    alpha = 0.8,
    width = 0.5
  ) +
  scale_y_continuous(
    breaks = seq(
      floor(min(df_limpo$escolarizacao_6a14, na.rm = TRUE)),
      ceiling(max(df_limpo$escolarizacao_6a14, na.rm = TRUE)),
      by = 2
    )
  ) +
  labs(
    title = "Boxplot da Escolarização (6 a 14 anos)",
    y = "Escolarização (%)",
    x = ""
  ) +
  theme_minimal() +
  theme(
    plot.title = element_text(hjust = 0.5, face = "bold", size = 14),
    axis.title = element_text(face = "bold"),
    axis.text.x = element_blank(),
    axis.ticks.x = element_blank()
  )

ggplot(df_limpo, aes(y = idhm)) +
  geom_boxplot(
    fill = "#5A84B3",
    color = "#1F4E79",
    alpha = 0.8,
    width = 0.5
  )

```

```

) +
scale_y_continuous(
  breaks = seq(
    floor(min(df_limpo$idhm, na.rm = TRUE) * 10) / 10,
    ceiling(max(df_limpo$idhm, na.rm = TRUE) * 10) / 10,
    by = 0.05
  )
) +
labs(
  title = "Boxplot do IDHM",
  y = "IDHM",
  x = ""
) +
theme_minimal() +
theme(
  plot.title = element_text(hjust = 0.5, face = "bold", size = 14),
  axis.title = element_text(face = "bold"),
  axis.text.x = element_blank(),
  axis.ticks.x = element_blank()
)

ggplot(df_limpo, aes(y = mortalidadeInfantil_obitosPor1000)) +
geom_boxplot(
  fill = "#5A84B3",
  color = "#1F4E79",
  alpha = 0.8,
  width = 0.5
) +
scale_y_continuous(
  breaks = pretty_breaks(n = 8)
) +
labs(
  title = "Boxplot da Mortalidade Infantil",
  y = "Óbitos por mil nascidos vivos",
  x = ""
) +
theme_minimal() +
theme(
  plot.title = element_text(hjust = 0.5, face = "bold", size = 14),
  axis.title = element_text(face = "bold"),
  axis.text.x = element_blank(),
  axis.ticks.x = element_blank()
)

```

```

)

ggplot(df_limpo, aes(y = pib_percapita)) +
  geom_boxplot(
    fill = "#5A84B3",
    color = "#1F4E79",
    alpha = 0.8,
    width = 0.5
  ) +
  scale_y_continuous(
    labels = label_number(big.mark = ".", decimal.mark = ","),
    breaks = pretty_breaks(n = 8)
  ) +
  labs(
    title = "Boxplot do PIB per Capita",
    y = "PIB per Capita (R$)",
    x = ""
  ) +
  theme_minimal() +
  theme(
    plot.title = element_text(hjust = 0.5, face = "bold", size = 14),
    axis.title = element_text(face = "bold"),
    axis.text.x = element_blank(),
    axis.ticks.x = element_blank()
  )
)

ggplot(df_limpo, aes(y = areaTerritorial_km2)) +
  geom_boxplot(
    fill = "#5A84B3",
    color = "#1F4E79",
    alpha = 0.8,
    width = 0.5
  ) +
  scale_y_continuous(
    labels = label_number(big.mark = ".", decimal.mark = ","),
    breaks = pretty_breaks(n = 8)
  ) +
  labs(
    title = "Boxplot da Área Territorial dos Municípios",
    y = "Área Territorial (km²)",
    x = ""
  ) +

```

```

theme_minimal() +
theme(
  plot.title = element_text(hjust = 0.5, face = "bold", size = 14),
  axis.title = element_text(face = "bold"),
  axis.text.x = element_blank(),
  axis.ticks.x = element_blank()
)

ggplot(df_limpo, aes(y = populacao_ultimoCenso)) +
  geom_boxplot(
    fill = "#5A84B3",
    color = "#1F4E79",
    alpha = 0.8,
    width = 0.5
  ) +
  scale_y_continuous(
    labels = label_number(big.mark = ".", decimal.mark = ","),
    breaks = pretty_breaks(n = 8)
  ) +
  labs(
    title = "Boxplot da População (Censo 2022)",
    y = "População (Habitantes)",
    x = ""
  ) +
  theme_minimal() +
  theme(
    plot.title = element_text(hjust = 0.5, face = "bold", size = 14),
    axis.title = element_text(face = "bold"),
    axis.text.x = element_blank(),
    axis.ticks.x = element_blank()
  )

ggplot(df_limpo, aes(y = densidadeDemografica)) +
  geom_boxplot(
    fill = "#5A84B3",
    color = "#1F4E79",
    alpha = 0.8,
    width = 0.5
  ) +
  scale_y_continuous(
    labels = label_number(big.mark = ".", decimal.mark = ","),
    breaks = pretty_breaks(n = 8)
  )

```

```

) +
labs(
  title = "Boxplot da Densidade Demográfica",
  y = "Densidade Demográfica (hab/km²)",
  x = ""
) +
theme_minimal() +
theme(
  plot.title = element_text(hjust = 0.5, face = "bold", size = 14),
  axis.title = element_text(face = "bold"),
  axis.text.x = element_blank(),
  axis.ticks.x = element_blank()
)

ggplot(df_limpo, aes(y = populacaoEstimada)) +
  geom_boxplot(
    fill = "#5A84B3",
    color = "#1F4E79",
    alpha = 0.8,
    width = 0.5
  ) +
  scale_y_continuous(
    labels = label_number(big.mark = ".", decimal.mark = ","),
    breaks = pretty_breaks(n = 8)
  ) +
  labs(
    title = "Boxplot da População Estimada (2025)",
    y = "População Estimada (Habitantes)",
    x = ""
  ) +
  theme_minimal() +
  theme(
    plot.title = element_text(hjust = 0.5, face = "bold", size = 14),
    axis.title = element_text(face = "bold"),
    axis.text.x = element_blank(),
    axis.ticks.x = element_blank()
  )

ggplot(df_limpo, aes(y = total_ReceitasBrutas)) +
  geom_boxplot(
    fill = "#5A84B3",
    color = "#1F4E79",

```



```

    alpha = 0.8,
    width = 0.5
  ) +
  scale_y_continuous(
    labels = label_number(big.mark = ".", decimal.mark = ",", prefix = "R$ "),
    breaks = pretty_breaks(n = 6)
  ) +
  labs(
    title = "Boxplot das Receitas Brutas Realizadas",
    y = "Total de Receitas Brutas (R$)",
    x = ""
  ) +
  theme_minimal() +
  theme(
    plot.title = element_text(hjust = 0.5, face = "bold", size = 14),
    axis.title = element_text(face = "bold"),
    axis.text.x = element_blank(),
    axis.ticks.x = element_blank()
  )

ggplot(df_limpo, aes(y = total_DespesasBrutas)) +
  geom_boxplot(
    fill = "#5A84B3",
    color = "#1F4E79",
    alpha = 0.8,
    width = 0.5
  ) +
  scale_y_continuous(
    labels = label_number(big.mark = ".", decimal.mark = ",", prefix = "R$ "),
    breaks = pretty_breaks(n = 6)
  ) +
  labs(
    title = "Boxplot das Despesas Brutas Empenhadas",
    y = "Total de Despesas Brutas (R$)",
    x = ""
  ) +
  theme_minimal() +
  theme(
    plot.title = element_text(hjust = 0.5, face = "bold", size = 14),
    axis.title = element_text(face = "bold"),
    axis.text.x = element_blank(),
    axis.ticks.x = element_blank()
  )

```

```

)

ggplot(df_limpo, aes(x = escolarizacao_6a14)) +
  geom_histogram(
    bins = 10,
    fill = "#7AB317",
    color = "black",
    alpha = 0.8
  ) +
  scale_x_continuous(
    breaks = seq(
      floor(min(df_limpo$escolarizacao_6a14, na.rm = TRUE)),
      ceiling(max(df_limpo$escolarizacao_6a14, na.rm = TRUE)),
      by = 2
    )
  ) +
  labs(
    title = "Distribuição da Escolarização (6 a 14 anos)",
    x = "Escolarização (%)",
    y = "Quantidade de Municípios"
  ) +
  theme_minimal() +
  theme(
    plot.title = element_text(
      hjust = 0.5,
      face = "bold",
      size = 14
    ),
    axis.title = element_text(face = "bold")
  )

ggplot(df_limpo, aes(x = idhm)) +
  geom_histogram(
    bins = 10,
    fill = "#7AB317",
    color = "black",
    alpha = 0.8
  ) +
  scale_x_continuous(
    breaks = seq(
      floor(min(df_limpo$idhm, na.rm = TRUE) * 10) / 10,
      ceiling(max(df_limpo$idhm, na.rm = TRUE) * 10) / 10,

```

```

    by = 0.05
  )
) +
labs(
  title = "Distribuição do IDHM",
  x = "IDHM",
  y = "Quantidade de Municípios"
) +
theme_minimal() +
theme(
  plot.title = element_text(
    hjust = 0.5,
    face = "bold",
    size = 14
  ),
  axis.title = element_text(face = "bold")
)

ggplot(df_limpo, aes(x = mortalidadeInfantil_obitosPor1000)) +
  geom_histogram(
    bins = 10,
    fill = "#7AB317",
    color = "black",
    alpha = 0.8
  ) +
  scale_x_continuous(
    breaks = pretty_breaks(n = 8)
  ) +
  labs(
    title = "Distribuição da Mortalidade Infantil",
    x = "Óbitos por mil nascidos vivos",
    y = "Quantidade de Municípios"
  ) +
  theme_minimal() +
  theme(
    plot.title = element_text(
      hjust = 0.5,
      face = "bold",
      size = 14
    ),
    axis.title = element_text(face = "bold")
  )
)

```

```

ggplot(df_limpo, aes(x = pib_percapita)) +
  geom_histogram(
    bins = 15,
    fill = "#7AB317",
    color = "black",
    alpha = 0.8
  ) +
  scale_x_continuous(
    labels = label_number(big.mark = ".", decimal.mark = ","),
    breaks = pretty_breaks(n = 8)
  ) +
  labs(
    title = "Distribuição do PIB per Capita",
    x = "PIB per Capita (R$)",
    y = "Quantidade de Municípios"
  ) +
  theme_minimal() +
  theme(
    plot.title = element_text(
      hjust = 0.5,
      face = "bold",
      size = 14
    ),
    axis.title = element_text(face = "bold"),
    axis.text.x = element_text(angle = 45, hjust = 1)
  )

ggplot(df_limpo, aes(x = areaTerritorial_km2)) +
  geom_histogram(
    bins = 15,
    fill = "#7AB317",
    color = "black",
    alpha = 0.8
  ) +
  scale_x_continuous(
    labels = label_number(big.mark = ".", decimal.mark = ","),
    breaks = pretty_breaks(n = 8)
  ) +
  labs(
    title = "Distribuição da Área Territorial dos Municípios",
    x = "Área Territorial (km²)",
    y = "Quantidade de Municípios"
  )

```

```

) +
theme_minimal() +
theme(
  plot.title = element_text(
    hjust = 0.5,
    face = "bold",
    size = 14
  ),
  axis.title = element_text(face = "bold"),
  axis.text.x = element_text(angle = 45, hjust = 1)
)

ggplot(df_limpo, aes(x = populacao_ultimoCenso)) +
  geom_histogram(
    bins = 20,
    fill = "#7AB317",
    color = "black",
    alpha = 0.8
  ) +
  scale_x_continuous(
    labels = label_number(big.mark = ".", decimal.mark = ","),
    breaks = pretty_breaks(n = 8)
  ) +
  labs(
    title = "Distribuição da População (Censo 2022)",
    x = "População (Habitantes)",
    y = "Quantidade de Municípios"
  ) +
  theme_minimal() +
  theme(
    plot.title = element_text(
      hjust = 0.5,
      face = "bold",
      size = 14
    ),
    axis.title = element_text(face = "bold"),
    axis.text.x = element_text(angle = 45, hjust = 1)
  )

ggplot(df_limpo, aes(x = densidadeDemografica)) +
  geom_histogram(
    bins = 15,

```

```

    fill = "#7AB317",
    color = "black",
    alpha = 0.8
) +
scale_x_continuous(
  labels = label_number(big.mark = ".", decimal.mark = ","),
  breaks = pretty_breaks(n = 8)
) +
labs(
  title = "Distribuição da Densidade Demográfica",
  x = "Densidade Demográfica (hab/km²)",
  y = "Quantidade de Municípios"
) +
theme_minimal() +
theme(
  plot.title = element_text(
    hjust = 0.5,
    face = "bold",
    size = 14
  ),
  axis.title = element_text(face = "bold"),
  axis.text.x = element_text(angle = 45, hjust = 1)
)

ggplot(df_limpo, aes(x = populacaoEstimada)) +
  geom_histogram(
    bins = 20,
    fill = "#7AB317",
    color = "black",
    alpha = 0.8
  ) +
  scale_x_continuous(
    labels = label_number(big.mark = ".", decimal.mark = ","),
    breaks = pretty_breaks(n = 8)
  ) +
  labs(
    title = "Distribuição da População Estimada (2025)",
    x = "População Estimada (Habitantes)",
    y = "Quantidade de Municípios"
  ) +
  theme_minimal() +
  theme(

```

```

    plot.title = element_text(
      hjust = 0.5,
      face = "bold",
      size = 14
    ),
    axis.title = element_text(face = "bold"),
    axis.text.x = element_text(angle = 45, hjust = 1)
  )

ggplot(df_limpo, aes(x = total_ReceitasBrutas)) +
  geom_histogram(
    bins = 20,
    fill = "#7AB317",
    color = "black",
    alpha = 0.8
  ) +
  scale_x_continuous(
    labels = label_number(big.mark = ".", decimal.mark = ",", prefix = "R$ "),
    breaks = pretty_breaks(n = 6)
  ) +
  labs(
    title = "Distribuição das Receitas Brutas Realizadas",
    x = "Total de Receitas Brutas (R$)",
    y = "Quantidade de Municípios"
  ) +
  theme_minimal() +
  theme(
    plot.title = element_text(
      hjust = 0.5,
      face = "bold",
      size = 14
    ),
    axis.title = element_text(face = "bold"),
    axis.text.x = element_text(angle = 45, hjust = 1)
  )

ggplot(df_limpo, aes(x = total_DespesasBrutas)) +
  geom_histogram(
    bins = 20,
    fill = "#7AB317",
    color = "black",
    alpha = 0.8
  )

```

```

) +
scale_x_continuous(
  labels = label_number(big.mark = ".", decimal.mark = ",", prefix = "R$ "),
  breaks = pretty_breaks(n = 6)
) +
labs(
  title = "Distribuição das Despesas Brutas Empenhadas",
  x = "Total de Despesas Brutas (R$)",
  y = "Quantidade de Municípios"
) +
theme_minimal() +
theme(
  plot.title = element_text(
    hjust = 0.5,
    face = "bold",
    size = 14
  ),
  axis.title = element_text(face = "bold"),
  axis.text.x = element_text(angle = 45, hjust = 1)
)

top10_area <- df_limpo %>%
  slice_max(areaTerritorial_km2, n = 10) %>%
  select(municipio, areaTerritorial_km2, populacao_ultimoCenso, densidadeDemografica, idhm, )
  arrange(desc(areaTerritorial_km2))

top10_area %>%
  mutate(
    areaTerritorial_km2 = label_comma(big.mark = ".")(round(areaTerritorial_km2, 1)),
    populacao_ultimoCenso = label_comma(big.mark = ".")(populacao_ultimoCenso),
    densidadeDemografica = round(densidadeDemografica, 2),
    pib_percapita = label_dollar(
      prefix = "R$ ",
      big.mark = ".",
      decimal.mark = ",",
    )(round(pib_percapita))
  ) %>%
  rename(
    Município = municipio,
    `Área (km²)` = areaTerritorial_km2,
    `Pop. 2022` = populacao_ultimoCenso,
    `Dens. (hab/km²)` = densidadeDemografica,
  )

```



```

    IDHM = idhm,
    `PIB pc (R$)` = pib_percapita
  ) %>%
  kable(
    caption = "10 municípios com maior área territorial (MG, 2025)",
    booktabs = TRUE,
    align = "lrrrrr"
  ) %>%
  kable_styling(latex_options = c("hold_position", "scale_down"))

top10_area %>%
  mutate(municipio = fct_reorder(municipio, areaTerritorial_km2)) %>%
  ggplot(aes(x = municipio, y = areaTerritorial_km2, fill = pib_percapita)) +
  geom_col(width = 0.7) +
  scale_fill_gradient(
    low = "#7AB317",
    high = "#2A044A",
    name = "PIB per capita",
    labels = label_dollar(prefix = "R$ ", big.mark = ".", decimal.mark = ",")
  ) +
  scale_y_continuous(labels = label_comma(big.mark = ".")) +
  coord_flip() +
  labs(title = "10 Maiores Municípios por Área Territorial",
       subtitle = "Cor indica PIB per capita - municípios maiores em extensão territorial",
       x = NULL,
       y = "Área (km²)"
  ) +
  theme_minimal() +
  theme(
    plot.title = element_text(hjust = 0.5, face = "bold", size = 14),
    axis.title = element_text(face = "bold"),
    axis.text.x = element_blank(),
    axis.ticks.x = element_blank()
  )

dados_graficos <- df_limpo

config_bolhas <- list(
  color = ~idhm,
  colorscale = "Viridis",
  showscale = TRUE,
  opacity = 0.8,

```

```

    line = list(color = "white", width = 0.5)
  )

# Configuração de layout
layout_padrao <- function(titulo, eixo_x, eixo_y, log_x = FALSE) {
  list(
    title = list(text = paste0("<b>", titulo, "</b>"), font = list(size = 18)),
    plot_bgcolor = "white",
    paper_bgcolor = "white",
    xaxis = list(
      title = paste0("<b>", eixo_x, "</b>"),
      gridcolor = "#e5e5e5",
      zeroline = FALSE,
      type = ifelse(log_x, "log", "linear")
    ),
    yaxis = list(
      title = paste0("<b>", eixo_y, "</b>"),
      gridcolor = "#e5e5e5",
      zeroline = FALSE
    ),
    hovermode = "closest"
  )
}

# Receitas Brutas x IDHM
grafico_receita_idhm <- plot_ly(
  data = dados_graficos,
  x = ~total_ReceitasBrutas,
  y = ~idhm,
  type = "scatter",
  mode = "markers",
  size = ~populacaoEstimada,
  sizes = c(5, 60),
  marker = config_bolhas,
  text = ~municipio,
  hovertemplate = paste0(
    "<b>{%text}</b><br>",
    "Receita Bruta: R$ {%x:,.2f}<br>",
    "IDHM: <b>{%y:.3f}</b><br>",
    "<extra></extra>"
  )
) %>%

```

```

layout(
  title = layout_padrao("Relação: Receita Bruta Municipal x IDHM",
                        "Total de Receitas Brutas (Escala Logarítmica)",
                        "Índice de Desenvolvimento Humano (IDHM)",
                        log_x = TRUE)$title,
  xaxis = layout_padrao("", "Receitas Brutas (Escala Logarítmica) (R$)", "", log_x = TRUE)$xaxis,
  yaxis = layout_padrao("", "", "IDHM")$yaxis,
  plot_bgcolor = "white", paper_bgcolor = "white"
)

# Escolarização x IDHM
grafico_escolarizacao_idhm <- plot_ly(
  data = dados_graficos,
  x = ~escolarizacao_6a14,
  y = ~idhm,
  type = "scatter",
  mode = "markers",
  size = ~populacaoEstimada,
  sizes = c(5, 60),
  marker = config_bolhas,
  text = ~municipio,
  hovertemplate = paste0(
    "<b>{text}</b><br>",
    "Taxa de Escolarização: {x}%<br>",
    "IDHM: <b>{y:.3f}</b><br>",
    "<extra></extra>"
  )
) %>%
layout(
  title = layout_padrao("Relação: Escolarização (6 a 14 anos) x IDHM",
                        "Taxa de Escolarização (%)",
                        "Índice de Desenvolvimento Humano (IDHM)")$title,
  xaxis = layout_padrao("", "Taxa de Escolarização (%)", "")$xaxis,
  yaxis = layout_padrao("", "", "Índice de Desenvolvimento Humano (IDHM)")$yaxis,
  plot_bgcolor = "white", paper_bgcolor = "white"
)

# IDHM x Mortalidade Infantil
grafico_idhm_mortalidade <- plot_ly(
  data = dados_graficos,
  x = ~idhm,
  y = ~mortalidadeInfantil_obitosPor1000,

```

```

type = "scatter",
mode = "markers",
size = ~populacaoEstimada,
sizes = c(5, 60),
marker = config_bolhas,
text = ~municipio,
hovertemplate = paste0(
  "<b>{%text}</b><br>",
  "IDHM: <b>{%x:.3f}</b><br>",
  "Mortalidade Infantil: {%y} óbitos/1000<br>",
  "<extra></extra>"
)
) %>%
layout(
  title = layout_padrao("O Impacto do IDHM na Mortalidade Infantil",
    "Índice de Desenvolvimento Humano (IDHM)",
    "Mortalidade Infantil (Óbitos por 1000)")$title,
  xaxis = layout_padrao("", "Índice de Desenvolvimento Humano (IDHM)", "")$xaxis,
  yaxis = layout_padrao("", "", "Mortalidade Infantil (Óbitos por 1000)")$yaxis,
  plot_bgcolor = "white", paper_bgcolor = "white"
)

browsable(
  tagList(
    div(style = "margin-bottom: 50px;", grafico_receita_idhm)
  )
)

par3 <- df_limpo %>%
  select(total_ReceitasBrutas, idhm) %>%
  na.omit()

r3 <- cor(par3$total_ReceitasBrutas, par3$idhm, method = "pearson")
rs3 <- cor(par3$total_ReceitasBrutas, par3$idhm, method = "spearman")

test3 <- cor.test(par3$total_ReceitasBrutas, par3$idhm)

cat("n =", nrow(par3), "\n")
cat("Pearson r =", round(r3, 3), "\n")
cat("Spearman rs =", round(rs3, 3), "\n")
cat("p-valor =", round(test3$p.value, 4), "\n")

```

```

browsable(
  tagList(
    div(style = "margin-bottom: 50px;", grafico_escolarizacao_idhm)
  )
)

par2 <- df_limpo %>%
  select(escolarizacao_6a14, idhm) %>%
  na.omit()

r2 <- cor(par2$escolarizacao_6a14, par2$idhm, method = "pearson")
rs2 <- cor(par2$escolarizacao_6a14, par2$idhm, method = "spearman")

test2 <- cor.test(par2$escolarizacao_6a14, par2$idhm)

cat("n =", nrow(par2), "\n")
cat("Pearson r =", round(r2, 3), "\n")
cat("Spearman rs =", round(rs2, 3), "\n")
cat("p-valor =", round(test2$p.value, 4), "\n")

browsable(
  tagList(
    div(style = "margin-bottom: 50px;", grafico_idhm_mortalidade)
  )
)

par1 <- df_limpo %>%
  select(idhm, mortalidadeInfantil_obitosPor1000) %>%
  na.omit()

r1 <- cor(par1$idhm, par1$mortalidadeInfantil_obitosPor1000, method = "pearson")
rs1 <- cor(par1$idhm, par1$mortalidadeInfantil_obitosPor1000, method = "spearman")

test1 <- cor.test(par1$idhm, par1$mortalidadeInfantil_obitosPor1000)

cat("n =", nrow(par1), "\n")
cat("Pearson r =", round(r1, 3), "\n")
cat("Spearman rs =", round(rs1, 3), "\n")
cat("p-valor =", round(test1$p.value, 4), "\n")

nova_paleta <- c("#2A044A", "#0B2E59", "#0D6759", "#7AB317", "#A0C55F")

```

```

grafico_pib_idhm <- plot_ly(
  data = df_limpo,
  x = ~pib_percapita,
  y = ~idhm,
  type = "scatter",
  mode = "markers",
  size = ~populacaoEstimada,
  sizes = c(6, 60),
  marker = list(
    color = ~idhm,
    colorscale = list(seq(0, 1, length.out = 5), nova_paleta),
    showscale = TRUE,
    colorbar = list(title = "<b>IDHM</b>", thickness = 15, len = 0.8),
    opacity = 0.85,
    line = list(color = "white", width = 0.8)
  ),
  text = ~municipio,
  hovertemplate = paste0(
    "<span style='font-size:16px;'><b>{%text}</b></span><br><br>",
    "<b>PIB per capita:</b> R$ {%x:,.2f}<br>",
    "<b>IDHM:</b> {%y:.3f}<br>",
    "<extra></extra>"
  )
) %>%
layout(
  title = list(text = "<b>Relação: PIB per capita vs. IDHM</b>", font = list(size = 20, color = "#f4f4f4", weight = "bold")),
  xaxis = list(title = "<b>PIB per capita (Escala Logarítmica)</b>", type = "log", gridcolor = "#f4f4f4", font = list(size = 12, color = "#f4f4f4", weight = "bold")),
  yaxis = list(title = "<b>Índice de Desenvolvimento Humano (IDHM)</b>", gridcolor = "#f4f4f4", font = list(size = 12, color = "#f4f4f4", weight = "bold")),
  plot_bgcolor = "white",
  paper_bgcolor = "white",
  hovermode = "closest",
  font = list(family = "Helvetica, Arial, sans-serif")
)

# Receitas vs Despesas
grafico_receita_despesa <- plot_ly(
  data = df_limpo,
  x = ~total_ReceitasBrutas,
  y = ~total_DespesasBrutas,
  type = "scatter",
  mode = "markers",
  size = ~populacaoEstimada,

```

```

sizes = c(6, 60),
marker = list(
  color = ~idhm,
  colorscale = list(seq(0, 1, length.out = 5), nova_paleta),
  showscale = TRUE,
  colorbar = list(title = "<b>IDHM</b>", thickness = 15, len = 0.8),
  opacity = 0.85,
  line = list(color = "white", width = 0.8)
),
text = ~municipio,
hovertemplate = paste0(
  "<span style='font-size:16px;'><b>{%text}</b></span><br><br>",
  "<b>Receita Bruta:</b> R$ {%x:,.2f}<br>",
  "<b>Despesa Bruta:</b> R$ {%y:,.2f}<br>",
  "<b>IDHM:</b> {%marker.color:.3f}<br>",
  "<extra></extra>"
)
)%>%
layout(
  title = list(text = "<b>Visão Financeira: Receitas vs. Despesas Brutas</b>", font = list(
  xaxis = list(title = "<b>Total de Receitas (Escala Logarítmica)</b>", type = "log", grid(
  yaxis = list(title = "<b>Total de Despesas (Escala Logarítmica)</b>", type = "log", grid(
  plot_bgcolor = "white",
  paper_bgcolor = "white",
  hovermode = "closest",
  font = list(family = "Helvetica, Arial, sans-serif"),
  shapes = list(
    list(
      type = "line",
      x0 = min(df_limpo$total_ReceitasBrutas, na.rm=TRUE),
      y0 = min(df_limpo$total_ReceitasBrutas, na.rm=TRUE),
      x1 = max(df_limpo$total_ReceitasBrutas, na.rm=TRUE),
      y1 = max(df_limpo$total_ReceitasBrutas, na.rm=TRUE),
      line = list(color = "#bdc3c7", dash = "dot", width = 2)
    )
  )
)
)
)

browsable(
  tagList(
    div(style = "margin-bottom: 60px; padding: 20px; border: 1px solid #eee; border-radius: 8px;")
  )
)

```

```

)

par4 <- df_limpo %>%
  select(pib_percapita, idhm) %>%
  na.omit()

r4 <- cor(par4$pib_percapita, par4$idhm, method = "pearson")
rs4 <- cor(par4$pib_percapita, par4$idhm, method = "spearman")

test4 <- cor.test(par4$pib_percapita, par4$idhm)

cat("n =", nrow(par4), "\n")
cat("Pearson r =", round(r4, 3), "\n")
cat("Spearman rs =", round(rs4, 3), "\n")
cat("p-valor =", round(test4$p.value, 4), "\n")

browsable(
  tagList(
    div(style = "margin-bottom: 40px; padding: 20px; border: 1px solid #eee; border-radius: 8px")
  )
)

par5 <- df_limpo %>%
  select(total_ReceitasBrutas, total_DespesasBrutas) %>%
  na.omit()

r5 <- cor(par5$total_ReceitasBrutas, par5$total_DespesasBrutas, method = "pearson")
rs5 <- cor(par5$total_ReceitasBrutas, par5$total_DespesasBrutas, method = "spearman")

test5 <- cor.test(par5$total_ReceitasBrutas, par5$total_DespesasBrutas)

cat("n =", nrow(par5), "\n")
cat("Pearson r =", round(r5, 3), "\n")
cat("Spearman rs =", round(rs5, 3), "\n")
cat("p-valor      =", round(test5$p.value, 4), "\n")

tabela_corr <- data.frame(
  Par = c(
    "IDHM × Mortalidade Infantil",
    "Escolarização × IDHM",
    "Receitas × IDHM",
    "PIB per capita × IDHM",
  )
)

```



```

      "Receitas × Despesas"
    ),
    n = c(nrow(par1), nrow(par2), nrow(par3), nrow(par4), nrow(par5)),
    Pearson_r = round(c(r1, r2, r3, r4, r5), 3),
    Spearman_rs = round(c(rs1, rs2, rs3, rs4, rs5), 3),
    Forca = c("Fraca", "Nula", "Fraca/Moderada*", "Moderada/Forte**", "Muito Forte"),
    Sentido = c("Negativo", "Negativo", "Positivo", "Positivo", "Positivo")
  )

knitr::kable(
  tabela_corr,
  col.names = c("Par de Variáveis", "n", "Pearson (r)",
                "Spearman (r)", "Força", "Sentido"),
  caption = "Resumo dos coeficientes de correlação - municípios de MG",
  align = c("l", "c", "c", "c", "c", "c")
)

variaveis_num <- df_limpo %>%
  select(areaTerritorial_km2, populacao_ultimoCenso, densidadeDemografica,
         escolarizacao_6a14, idhm, mortalidadeInfantil_obitosPor1000,
         total_ReceitasBrutas, total_DespesasBrutas, pib_percapita)

matriz_cor <- cor(variaveis_num, method = "pearson",
                  use = "pairwise.complete.obs")

rownames(matriz_cor) <- colnames(matriz_cor) <- c(
  "Área", "Pop. Censo", "Densidade", "Escolariz.",
  "IDHM", "Mort. Inf.", "Receitas", "Despesas", "PIB pc"
)

paleta_matriz <- colorRampPalette(c("#29044a", "#0b2e58", "#ffffff",
                                   "#7ab318", "#a0c55e"))(200)

corrplot(matriz_cor,
         method = "color",
         type = "upper",
         addCoef.col = "black",
         number.cex = 0.75,
         tl.col = "black",
         tl.srt = 45,
         col = paleta_matriz,
         mar = c(0, 0, 2, 0),

```

```
title = "Matriz de Correlação de Pearson - Municípios de MG")
```